

Application pratique

Estimateur MV de translation
subpixellique entre deux images

Les images à utiliser

- Les images sont des simulations d'images optiques à 70 cm de resolution spatiale (port de Marseille)
- Les images sont codées sur 16bits non signés (0 à $2^{16}-1$) en png
- L'*image_0.png* est l'image de reference géométrique
- Les images *image_1_delta%02d.png* sont 50 images décalées avec des translations aléatoires non entières entre -3 et +3 pixels en ligne et en colonne



Notations

- Chaque image est bruitée d'un bruit blanc gaussien de moyenne nulle
- Si O est l'image "idéale", alors
 - L'image de reference peut se noter comme :
 $I_0(x, y) = O(x, y) + b_0(x, y)$ où $b_0 \sim N(0, \sigma_b)$
 - Les 50 images translatées peuvent se noter comme :
 $I_{1,k}(x, y) = O(x - \delta_{x,k}, y - \delta_{y,k}) + b_1(x, y)$ où $b_1 \sim N(0, \sigma_b)$
 $\delta_{x,k}$: translation en colonne sur $[-3, 3]$
 $\delta_{y,k}$: translation en ligne sur $[-3, 3]$

Etape 1

- Ecrire une fonction qui évalue la distance euclidienne entre une **vignette de contexte** C de rayon rc et une **zone de recherche** R de rayon $rc+rr$ (où rr est le rayon max de recherche).
Par exemple, dans notre cas, pour un point d'intérêt (x_0, y_0)
 - La vignette de contexte est extraite de I_0 :
$$C = I_0(x_0 + [-rc:rc], y_0 + [-rc:rc])$$
 - La zone de recherche est extraite de $I_{1,k}$:
$$R = I_{1,k}(x_0 + [-rr - rc:rr + rc], y_0 + [-rr - rc:rr + rc])$$
- En sortie, une matrice de distance D de taille $(2rr + 1) \times (2rr + 1)$
- Attention au temps de calcul : pensez à bien utiliser la *vectorialisation* des calculs.
Bonus : on accélérer les calculs très nettement en utilisant la convolution par FFT
....

Etape 2

- Ecrire une fonction qui détermine le lieu « subpellique » du minimum de D
 - Localiser le lieu discret du min de D
 - Dans le voisinage direct de ce minimum, on peut faire l'hypothèse d'une forme quadratique de D :
$$D(dx, dy) \cong \alpha_1 dx^2 + \alpha_2 dx dy + \alpha_3 dy^2 + \alpha_4 dx + \alpha_5 dy + \alpha_6$$
 - Par régression linéaire, évaluer les $\{\alpha_i\}$
 - En déduire la position non-entière (sub-pixelique) (dx_{min}, dy_{min}) de D en résolvant les équations linéaires
 - $\frac{\partial D}{\partial dx} = 0$
 - $\frac{\partial D}{\partial dy} = 0$

Etape 3

- Choisir un point particulier dans l'image de référence
- Choisir $rc = 10$ et $rr = 6$
- Déterminer le vecteur de translation entre l'image de référence et les 50 images
Celui dont l'erreur d'évaluation de translation sur un point est la plus faible gagne le pompon 😊
- A l'aide d'une estimation de la matrice d'information de Fisher, proposer un modèle pour l'erreur quadratique moyenne (hors biais)
- Proposer une méthode permettant d'évaluer ce modèle d'erreur sur plusieurs points

Rappel

Soient N valeurs de s_k telles que

$$s_k = s(t_k) = s_0(t_k - \delta) + b_k \quad \text{où } b \sim \mathcal{N}(0, \sigma_b)$$

Le paramètre à estimer est δ

La log-vraisemblance LV s'exprime alors :

$$LV(\tau) = \log P(S|\tau) = K - \frac{1}{2\sigma_b^2} \sum_{k=1}^N (s_k - s_0(t_k - \tau))^2$$

L'estimateur LV de δ est donc $\hat{\delta} = \operatorname{argmax} LV(\tau)$

En supposant que τ est \ll devant l'extension temporel de s_k , on peut considérer $\sum_{k=1}^N s_0(t_k - \tau)^2$ indépendant de τ et

$$LV(\tau) = K' - \frac{1}{\sigma_b^2} \sum_{k=1}^N s_k s_0(t_k - \tau)$$

Rappel

- Par Parseval et en notant $TF[s_0](f)$ la transformée de Fourier de s_0

$$\frac{1}{\sigma_b^2} \sum_{k=1}^N s_k s_0(t_k - \tau) = \frac{1}{\sigma_b^2} \int [TF[s_0]]^2 e^{-2i\pi f(\delta - \tau)} df$$

- La matrice d'information de Fisher $IF(\delta)$ peut donc s'écrire :

$$IF(\delta) = \frac{\partial^2 LV}{\partial \tau} (\tau = \delta) = -\frac{4\pi^2}{\sigma_b^2} \int f^2 [TF[s_0]]^2 df$$

En remarquant que $TF \left[\frac{ds_0}{dt} \right] = 2i\pi TF[s_0]$ et en appliquant Parseval, on a

$$IF(\delta) = -\frac{4\pi^2}{\sigma_b^2} \left\| \frac{ds_0}{dt} \right\|_{L_2}^2$$

Rappel

- En 2d, pour une image J (ou une vignette d'une image)

$$IF(\delta_x, \delta_y) = -\frac{4\pi^2}{\sigma_b^2} \begin{bmatrix} \|\nabla_x(J)\|_{L2}^2 & \langle \nabla_x(J), \nabla_y(J) \rangle \\ \langle \nabla_x(J), \nabla_y(J) \rangle & \|\nabla_y(J)\|_{L2}^2 \end{bmatrix}$$

Où $\nabla_d(J)$ est le gradient de J suivant la direction d

Cette matrice est symétrique positive, elle peut être diagonalisée. Ses valeurs propres représentent les variances minimales sur les axes principaux